Análisis exploratorio de datos de liquidación y facturación

Calidad, estructura y patrones descriptivos en un conjunto sintético

Camilo Cepeda Orduz

Fundación de Educación Superior San José

Seminario de Inteligencia Artificial

Docente: Winder Osorio

23 de octubre de 2026

Análisis exploratorio de datos de liquidación y facturación

Resumen

Se examinó un conjunto sintético de liquidaciones, detalles de servicio e historial de estados para describir su calidad, estructura y patrones, sin inferir resultados de una empresa real. El análisis parte de 4.536 filas crudas de detalle y conserva 4.448 después de retirar 66 duplicados exactos y 22 referencias huérfanas; las cabeceras comprenden 134 liquidaciones distribuidas en 24 meses, de septiembre de 2024 a agosto de 2026. Se revisaron formatos, valores faltantes, integridad de relaciones, valores extremos por tarifa, correlaciones, composición de conceptos y tiempos de transición. Se identificaron 356 filas limpias sin número de planilla (8,0 %) y 122 registros marcados mediante el criterio del rango intercuartílico (2,7 %). Estos resultados describen únicamente los archivos generados para el ejercicio. Las alertas sirven para priorizar revisiones y no constituyen errores confirmados, fraude, incumplimiento ni una medida de desempeño real.

Palabras clave: análisis exploratorio, calidad de datos, datos sintéticos, liquidaciones

Introducción

El análisis exploratorio permite entender la forma, la calidad y el contexto de los datos antes de construir indicadores. En un tablero de gestión, una cifra legible no garantiza que su agrupación sea correcta: los campos deben conservar significado, trazabilidad y consistencia con el uso previsto (Wang & Strong, 1996). Por ello, este informe examina primero las fuentes y reglas de preparación y luego describe los patrones que orientan el tablero del proyecto.

El propósito fue documentar qué contiene el conjunto, qué transformaciones se aplicaron, cuáles limitaciones afectan la interpretación y qué señales requieren verificación. El proyecto emplea registros generados con fines académicos. No son transacciones de una organización ni una muestra representativa del sector.

Método

Se revisaron tres fuentes de entrada: una hoja de cálculo de cabeceras, un archivo separado por comas con ítems de servicio y un historial de estados. El detalle crudo contiene 4.536 filas; la tabla de cabeceras contiene 134 liquidaciones y cubre 24 meses entre septiembre de 2024 y agosto de 2026. Los archivos depurados del proyecto y las reglas reproducibles del proceso de extracción, transformación y carga se usaron como base de contraste (Cepeda Orduz, 2026).

La preparación conserva el texto original para detectar problemas de forma, convierte los valores a tipos analizables, retira duplicados exactos y excluye referencias huérfanas del conjunto limpio. Los valores faltantes se interpretan por campo, porque un espacio vacío puede ser válido por diseño o afectar la trazabilidad. Las estadísticas son descriptivas y las relaciones no se interpretan como causales.

Para localizar valores extremos se calculó el rango intercuartílico por tipo de tarifa; se marcó cada valor por debajo de Q1 - 1,5 × RIQ o por encima de Q3 + 1,5 × RIQ. El criterio sigue la propuesta exploratoria de Tukey (1977). Los registros marcados se conservan: la regla prioriza revisión, pero no determina por sí sola que el dato sea erróneo.

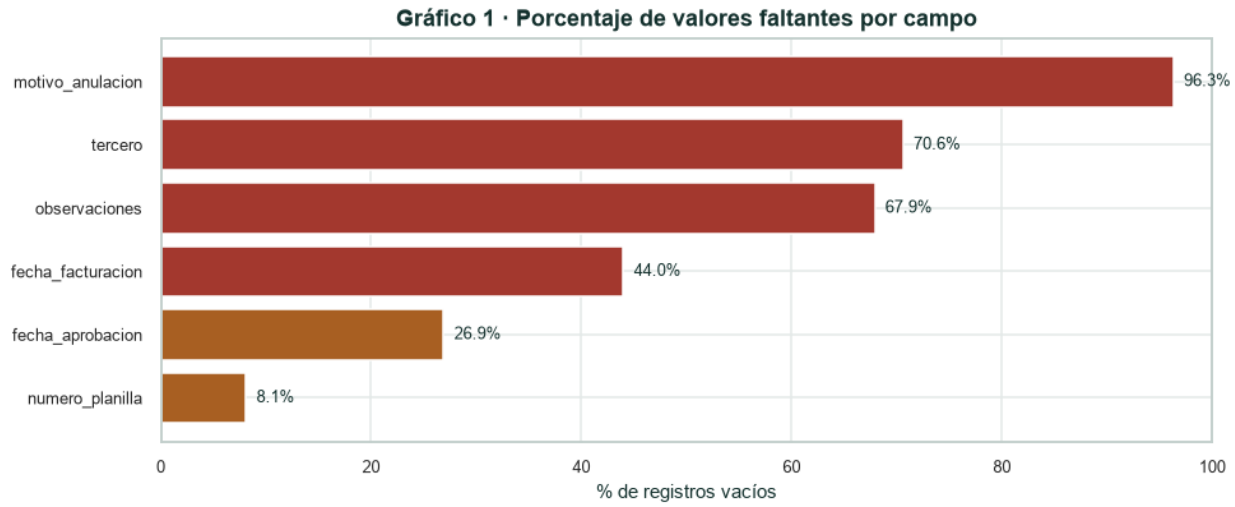
Resultados: calidad y trazabilidad

La depuración reduce el detalle de 4.536 a 4.448 filas al retirar 66 duplicados exactos y 22 referencias sin cabecera asociada. En la tabla limpia, 356 filas (8,0 %) no contienen número de planilla. Esa ausencia requiere cotejo documental si se tratara de una operación real; por sí sola no demuestra que el servicio no ocurriera.

En los archivos de entrada también se identificaron 903 placas que no cumplen el patrón sintético VEH-000, 1.130 fechas iniciales fuera del patrón ISO y 917 valores unitarios con símbolo monetario o separador local. Los grupos pueden solaparse y no deben sumarse como filas únicas con error. La Figura 1 muestra los campos faltantes y ayuda a separar ausencias válidas por diseño de vacíos que afectan la trazabilidad.

Figura 1

Campos con valores faltantes en las fuentes analizadas



Nota. El porcentaje se calcula sobre cada archivo. Algunos vacíos son condicionales o válidos por diseño; el número de planilla se considera una señal de trazabilidad.

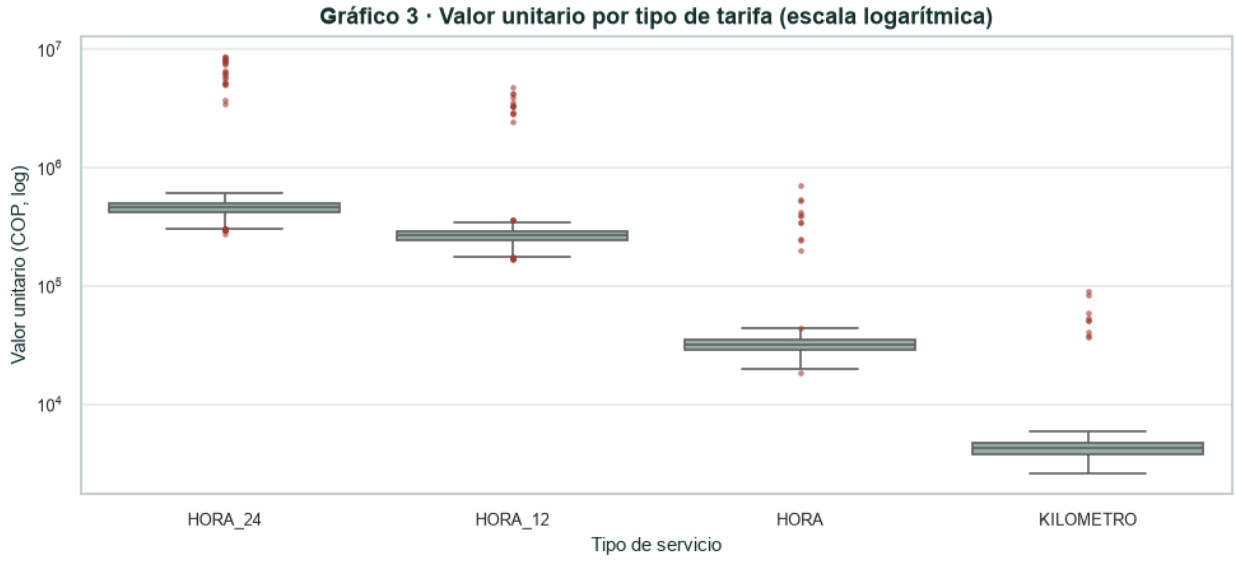
Resultados: estructura y valores extremos

El detalle limpio reúne 1.986 ítems HORA_24, 1.106 HORA_12, 835 HORA y 521 KILOMETRO. Las cantidades y tarifas pertenecen a escalas distintas; comparar directamente una tarifa por kilómetro con una tarifa por hora produciría contrastes poco informativos. Por esa razón, los extremos de valor unitario se evaluaron dentro de cada tipo de servicio.

El criterio intercuartílico marcó 122 de 4.448 ítems (2,7 %): 53 HORA_24, 32 HORA_12, 20 HORA y 17 KILOMETRO. La Figura 2 permite ver la distribución separada por tarifa. Un valor extremo no significa error, fraude o incumplimiento; el registro se conserva y requeriría revisar cantidad, tarifa, condiciones y soporte antes de decidir cualquier ajuste (Tukey, 1977).

Figura 2

Distribución del valor unitario según el tipo de tarifa



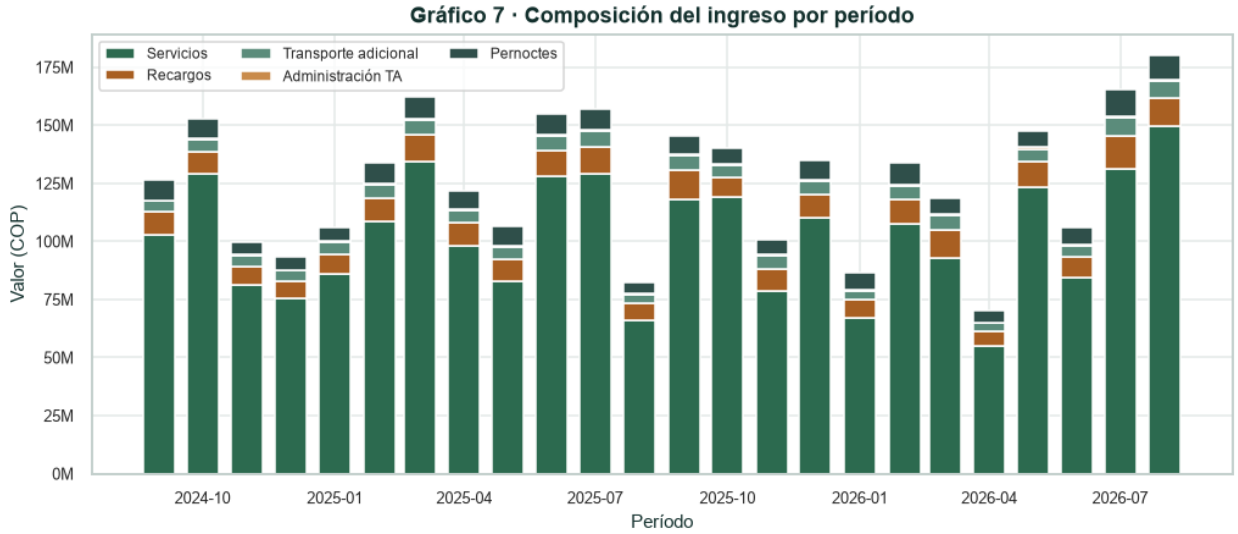
Nota. Las escalas se analizan por separado para evitar comparaciones directas entre modalidades de cobro distintas.

Resultados: composición de los componentes

En los componentes del subtotal, el servicio base representa 81,6 %, los recargos 7,9 %, los pernoctes 6,1 % y el transporte adicional 4,3 %. La Figura 3 presenta esa composición para el conjunto sintético. No equivale a utilidad ni rentabilidad: el proyecto no incorpora costos operativos.

Figura 3

Participación de los componentes del subtotal



Nota. Los porcentajes corresponden a los conceptos incluidos en la comparación; los valores se generaron para el ejercicio.

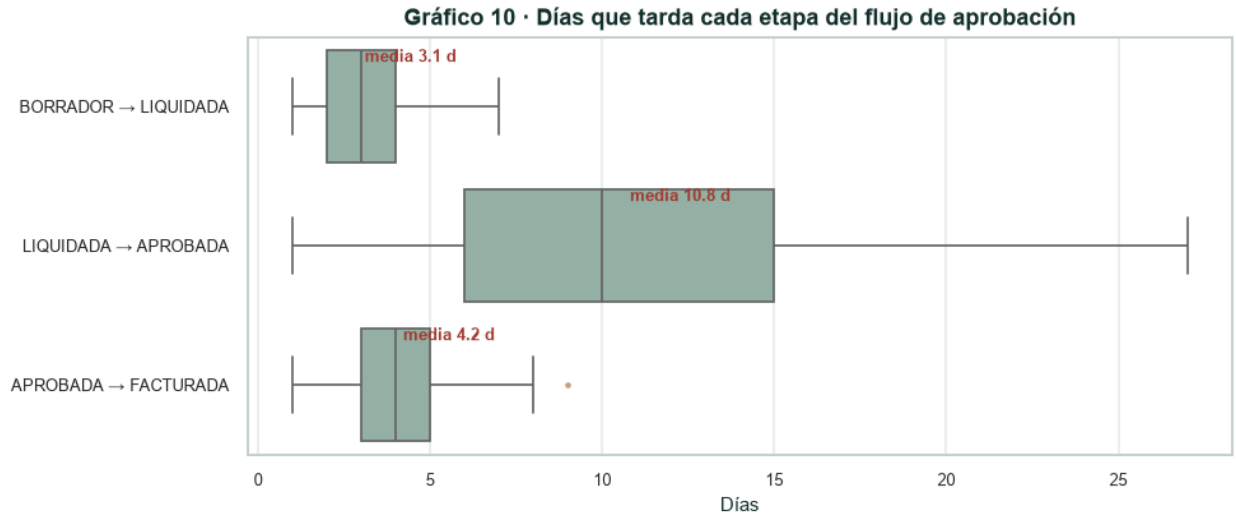
Resultados: tiempos y relaciones

En el historial, la transición de borrador a liquidada promedia 3,1 días; de liquidada a aprobada, 10,8 días; y de aprobada a facturada, 4,2 días. La etapa entre liquidación y aprobación es la de mayor duración media dentro de este conjunto. La Figura 4 presenta esos promedios, que no representan un acuerdo de nivel de servicio ni permiten generalizar a una organización.

La relación negativa observada entre cantidad y valor unitario se explica en parte por la mezcla de tarifas por kilómetro y por hora. Es una asociación descriptiva condicionada por la estructura del servicio, no evidencia causal.

Figura 4

Duración media de las transiciones registradas



Nota. Promedios descriptivos calculados a partir del historial de estados sintético.

Discusión y conclusiones

Los resultados muestran por qué la preparación debe conservar el vínculo entre detalle y cabecera y normalizar formatos antes de agregar. La duplicación y las referencias huérfanas explican la diferencia entre filas crudas y limpias. La ausencia de planilla concentra la principal señal de trazabilidad, mientras que las variantes de placa, fecha y moneda exigen reglas explícitas y auditables. Estas dimensiones son complementarias a la exactitud de un dato y deben interpretarse según el uso que se le dará (Wang & Strong, 1996).

De forma similar, la duración mayor de liquidada a aprobada identifica un punto que merece atención en el conjunto generado, pero no establece un cuello de botella real.

Como conclusión, el proceso documenta reglas reproducibles para duplicados, relaciones, catálogos, importes y fechas; el criterio intercuartílico funciona como priorización de revisión; y las duraciones describen las transiciones disponibles. En un uso operativo, los faltantes y alertas deberían contrastarse con soportes y responsables antes de corregir o decidir.

Limitaciones

Los registros son sintéticos y no proceden de una empresa. No prueban estacionalidad, demanda, desempeño, fraude, ahorro ni resultados sectoriales. Los conteos de defectos de formato pueden solaparse; las correlaciones pueden reflejar escalas de tarifa; el rango intercuartílico depende de la distribución y tamaño de cada grupo; y los promedios de tiempo dependen de los estados y fechas presentes. No se estimaron costos, margen o rentabilidad.

Referencias

Cepeda Orduz, C. (2026). *Datos sintéticos de liquidaciones y archivos depurados del proyecto* [Conjunto de datos de práctica]. Fundación de Educación Superior San José.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems, 12*(4), 5-34. https://doi.org/10.1080/07421222.1996.11518099