Calidad del dato antes del algoritmo: aprendizajes de un dashboard de liquidaciones de transporte especial

Camilo Cepeda Orduz

Fundación de Educación Superior San José

Opción de grado: Seminario de Inteligencia Artificial (2026-2)

Octubre de 2026

Calidad del dato antes del algoritmo: aprendizajes de un dashboard de liquidaciones de transporte especial

En proyectos de inteligencia artificial, la atención suele centrarse en el modelo y su capacidad predictiva. Pero en una liquidación, la utilidad de una salida automatizada depende de que los registros representen lo ocurrido: un duplicado puede inflar un valor, una referencia rota impedir su conciliación y una fecha incompleta alterar el tiempo de ciclo. La calidad del dato repercute así en la lectura operativa.

¿Puede un algoritmo compensar los defectos de los datos que recibe? La calidad no se reduce a la exactitud: también importan la completitud, la relación con la fuente, la oportunidad y la utilidad para una decisión concreta (Wang & Strong, 1996). Por ello, medirla exige definir qué significa “adecuado” para cada uso.

Este ensayo sostiene que validar y documentar los datos debe preceder a la automatización con inteligencia artificial. La tesis se examina a partir de LIQUIDA, proyecto académico que implementó ETL, análisis exploratorio y un dashboard Power BI para liquidaciones de transporte especial. No entrenó un modelo predictivo: usa datos sintéticos para estudiar preparación y lectura, no el desempeño de una empresa real.

La calidad como condición de la analítica y la inteligencia artificial

La calidad depende del uso. Un dato válido en una tabla puede ser insuficiente para conciliar pagos si carece de soporte. La norma ISO/IEC 25012 distingue atributos propios de los datos y otros que dependen del sistema que los produce o consume (International Organization for Standardization, 2008). Así, una noción amplia se traduce en controles observables: completitud, unicidad, integridad referencial, consistencia y oportunidad.

Estos controles forman parte del ciclo analítico, no son una tarea aislada. CRISP-DM conecta comprensión del negocio, preparación y evaluación de los datos (Chapman et al., 2000). En aprendizaje automático, dependencias, señales cambiantes y mantenimiento pueden acumular deuda técnica (Sculley et al., 2015); decisiones poco visibles de recolección, etiquetado o limpieza también pueden propagarse a resultados posteriores (Sambasivan et al., 2021).

El proyecto de liquidación y la evidencia disponible

LIQUIDA integra cabeceras, ítems e historial de estados. El ETL en Python normaliza campos, depura registros, calcula variables y ejecuta nueve validaciones; sus tablas alimentan tres vistas de un informe Power BI. El análisis comprende 134 liquidaciones, 4.448 ítems limpios y 428 eventos de estado, todos sintéticos y creados con fines académicos.

Se partió de 4.536 ítems: se retiraron 66 duplicados exactos y 22 filas sin liquidación relacionada. De los 4.448 restantes, 356 (8,0 %) no tenían número de planilla. El faltante exige cotejo documental, pero no demuestra que el servicio no se prestó. Ocho validaciones quedaron “OK”; la novena avisó de una diferencia superior al 1 % entre cabecera y detalle en una liquidación. Es una alerta para revisar, no un error confirmado.

El EDA también calculó un puntaje compuesto de calidad de 89,6/100. Resume dimensiones definidas para este ejercicio, pero depende de las reglas y ponderaciones elegidas: no es certificación, medida normalizada ni KPI operativo del dashboard. Debe leerse junto a sus componentes.

Las tres páginas del informe separan la visión ejecutiva, el detalle operacional y los tiempos comparativos. Esa navegación permite pasar de la síntesis a la exploración, pero no convierte un valor agregado en una explicación causal ni en una predicción. Al segmentar por período cambia el conjunto comparado; por eso, además del valor, deben comunicarse el filtro aplicado y la cantidad de casos que lo sustentan.

Interpretar los indicadores sin exceder la evidencia

La regla del rango intercuartílico de Tukey (1977) señaló 122 valores unitarios como atípicos (2,7 % de los ítems depurados). “Atípico” indica distancia respecto de la distribución central, no fraude ni error confirmado. La alerta puede priorizar una revisión; antes de ajustar un pago, una persona debe contrastarla con la tarifa, el servicio y sus soportes.

Los tiempos exigen denominadores visibles: el ciclo liquidación-facturación promedió 18,1 días en 75 casos facturados con duración registrada; la transición liquidada-aprobada, 10,8 días en 98 eventos. Describen el conjunto sintético, no prueban un cuello de botella ni una mejora. Comparar períodos requiere mantener definiciones y filtros equivalentes.

Podría objetarse que un modelo robusto tolera ruido. Algunas técnicas resisten errores aleatorios, pero no determinan si un campo faltante debe existir, si una fuente tiene el significado esperado o qué regla de negocio aplicar. Northcutt et al. (2021) hallaron errores de etiquetado en diez conjuntos de prueba de aprendizaje automático; su promedio de 3,3 % no es trasladable a liquidaciones, pero recuerda que hasta los datos de referencia requieren auditoría. La lección es metodológica, no una comparación de tasas.

Gobernanza antes de automatizar

Una práctica útil documenta la procedencia, los campos, las transformaciones, los denominadores y las reglas. Separa alertas de incidencias confirmadas, asigna responsables y registra las excepciones. Si LIQUIDA incorporara modelos, necesitaría etiquetas verificadas, datos de evaluación representativos, seguimiento de cambios y revisión humana en decisiones con efectos económicos o personales.

Los datos sintéticos limitan las conclusiones: no describen a personas ni empresas reales. Si una fase posterior usara información personal, habría que revisar finalidades, accesos, seguridad y obligaciones aplicables, incluida la Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012). La limpieza técnica no reemplaza esa revisión.

Conclusión

LIQUIDA respalda una conclusión acotada: antes de confiar una decisión a un algoritmo, hay que conocer sus datos, controles e incertidumbres. El ETL y Power BI hicieron visibles duplicados, referencias rotas, soportes faltantes, atípicos y tiempos con muestras distintas. El conjunto sintético no demuestra predicción ni rendimiento empresarial, pero ofrece una base reproducible para preparar una eventual automatización. Primero se valida la evidencia; después se decide si la IA aporta valor.

Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium. https://www.the-modeling-agency.com/crisp-dm.pdf

Congreso de la República de Colombia. (2012, 17 de octubre). Ley Estatutaria 1581 de 2012: Por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587. https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

International Organization for Standardization. (2008). *ISO/IEC 25012:2008: Software engineering—Software product quality requirements and evaluation (SQuaRE)—Data quality model*. https://www.iso.org/standard/35736.html

Northcutt, C. G., Athalye, A., & Mueller, J. (2021). Pervasive label errors in test sets destabilize machine learning benchmarks. *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks, 1*. https://datasets-benchmarks-proceedings.neurips.cc/paper_files/paper/2021/hash/f2217062e9a397a1dca429e7d70bc6ca-Abstract.html

Sambasivan, N., Kapania, S., Highfill, H., Akrong, D., Paritosh, P., & Aroyo, L. (2021). "Everyone wants to do the model work, not the data work": Data cascades in high-stakes AI. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems* (pp. 1-15). Association for Computing Machinery. https://doi.org/10.1145/3411764.3445518

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems, 28*, 2503-2511. https://proceedings.neurips.cc/paper_files/paper/2015/hash/86df7dcfd896fcaf2674f757a2463eba-Abstract.html

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems, 12*(4), 5-33. https://doi.org/10.1080/07421222.1996.11518099